

概率图模型

一、背景 =
高维随机变量 $P(x_1, x_2, \dots, x_p)$ $\left\{ \begin{array}{l} \text{边缘概率 } P(x_i) \\ \text{条件概率 } P(x_j | x_i) \end{array} \right.$

在计算过程中的重要法则：


1. 加法法则： $P(x_1) = \int P(x_1, x_2) dx_2$

2. 乘法法则： $P(x_1, x_2) = P(x_1)P(x_2 | x_1) = P(x_2)P(x_1 | x_2)$

Chain Rule : $P(x_1, x_2, \dots, x_p) = P(x_1)P(x_2 | x_1) \cdot P(x_3 | x_1, x_2) \cdots P(x_p | x_1, x_2, \dots, x_{p-1})$

贝叶斯定理： $P(x_1 | x_2) = \frac{P(x_1, x_2)}{P(x_2)} = \frac{P(x_1, x_2)}{\int P(x_1, x_2, x_3, \dots, x_p) dx_3 \dots dx_p} = \frac{P(x_2)P(x_1 | x_2)}{\int P(x_2)P(x_1 | x_2) dx_1}$


困境：维度高，计算复杂， $P(x_1, x_2, \dots, x_p)$ 计算量太大。



要把概率的概念引伸到图的结构上，需要能够有效地表现条件独立性。

条件独立性

$x_a \perp x_b | x_c, \quad x_a, x_b, x_c \text{ 不是集合且不相交.}$



二、贝叶斯网络（有向图）


$$P(x_1, x_2, \dots, x_p) = P(x_1) \cdot \prod_{i=2}^p P(x_i | x_1, \dots, x_{i-1})$$

条件独立性： $x_A \perp x_C | x_B$

$$\text{因子分解} = \text{联合概率 } P(x_1, x_2, \dots, x_p) = \prod_{i=1}^p P(x_i | x_{\text{par}(i)})$$

$x_{\text{par}(i)}$ 是 x_i 的父集

例如有向图：



(tail to tail)

$$c \perp b | a$$

↓

若 a 被观测，则路径被阻塞。

$$\text{由因子分解式: } P(a, b, c) = P(a) P(b|a) P(c|a)$$

$$\text{由链式法则: } P(a, b, c) = P(a) P(b|a) P(c|a, b)$$

$$\Rightarrow P(c|a) = P(c|a, b) \Rightarrow b \text{ 与 } c \text{ 独立.}$$

↓

$$P(c|a)P(b|a) = P(c|a, b)P(b|a) = P(b, c|a)$$

$$P(c|a) \cdot P(b|a) = P(b, c|a) \Rightarrow b \text{ 与 } c \text{ 独立}$$




(head to tail)

$$a \perp c | b$$

↓

若 b 被观测，则路径被阻塞。

观测，路径也是通的。



(head to head)

a 和 b 先天独立，若 c 被观测，则路径是通的。（自后往前节点被

$$P(a, b, c) = P(a) P(b) P(c|a, b)$$

$$P(a, b, c) = P(a) P(b|a) P(c|a, b)$$

$$\Rightarrow P(b) = P(b|a) \Rightarrow a, b \text{ 独立}$$


若 b_1 满足 head to head，则该节点不能在 x_B 内部，包括其后进节点

D-Separation (D 划分)

划分规则：

① head to tail tail to tail

② head to head




遵循划分规则
为全局 Markov Property

若 b_1 满足 head to tail，则该节点一定在 x_B 内部
若 b_2 满足 tail to tail，则该节点一定在 x_B 内部

$$P(x_i | x_{-i}) = \frac{p(x_i, x_{-i})}{p(x_{-i})} = \frac{p(x)}{\int_x p(x) dx_i} = \frac{\prod_{j=1}^J p(x_j | x_{pa(j)})}{\int_{x_i} \prod_{j=1}^J p(x_j | x_{pa(j)}) dx_i}$$

将与 x_i 有关的设为 A，与 x_i 无关的设为 B，
则 $P(x_i | x_{-i}) = f(A)$

其中与 x_i 无关的信息可以忽略
即与 x_i 前面分子中的无关变量均被掉




Bayesian Network.

Bayesian Network

从单一到混合
从有限到无限

空间
(离散→连续)
时间

单一：Naive Bayes $\rightarrow P(x|y) = \prod_{i=1}^n P(x_i | y=1)$
混合：高斯混合模型 (GMM, 用于聚类)
时间：
空间：
连续：Gaussian Bayesian Network




三. 马尔可夫随机场(马尔可夫网图) (无向图)

① $x_A \perp x_C \mid x_B$. x_B 到 x_C 路径上至少有一个点在 x_B 中, 则 x_A 与 x_C 条件独立.

全局马尔可夫

② 局部马尔可夫



$a \perp \{ \text{全集} - a - \text{邻居} \} \mid \text{邻居}$

$a \perp \{ e, f \} \mid \{ b, c, d \}$

③ 成对马尔可夫

$$x_i \perp x_j \mid x_{-i-j} \quad (i \neq j)$$

条件独立性体现在以上三个方面 ①全局 ②局部 ③成对.

$$\text{且 } ① \Leftrightarrow ② \Leftrightarrow ③$$

因子分解.

团: 团是关于节点的集合, 集合中的节点之间相互都是连通的.

最大团: 再添加任何一个节点就不是团的团.

$$P(X) = \frac{1}{Z} \prod_{i=1}^k \phi(x_{c_i})$$

C_i : 最大团

X_{c_i} : 最大团随机变量集合

$\phi(x_{c_i})$ 势函数, 必须为正

$$Z = \sum_{\mathcal{X}} \prod_{i=1}^k \phi(x_{c_i}) = \sum_{\mathcal{X}_1} \dots \sum_{\mathcal{X}_n} \prod_{i=1}^k \phi(x_{c_i}), \text{ 归一化因子.}$$

- 一般来讲 $\phi(x_{c_i}) = \exp\{-E(x_{c_i})\}$, 此时 $P(X)$ 被称做吉布斯分布 (Gibbs) 或玻尔兹曼分布.

$$P(X) = \frac{1}{Z} \prod_{i=1}^k \phi(x_{c_i}) = \frac{1}{Z} \prod_{i=1}^k \exp\{-E(x_{c_i})\} = \frac{1}{Z} \exp\left\{-\sum_{i=1}^k E(x_{c_i})\right\}$$

Markov Random Field \Leftrightarrow Gibbs Distribution

Inference 推断


P1 推断的目的就是求概率

$$\text{求概率} \quad P(X) = P(X_1, X_2, \dots, X_p)$$

$$\text{边缘概率} : P(X_i) = \sum_{x_1} \sum_{x_2} \dots \sum_{x_{i-1}} \sum_{x_{i+1}} \dots \sum_{x_p} P(X)$$

$$\text{条件概率} : P(X_A | X_B) \quad X = X_A \cup X_B$$

$$\leftarrow \text{MAP Inference} : \hat{z} = \arg \max_z P(z|X) \propto \arg \max_z P(z, X)$$



P2. Variable Elimination.

例如有马氏链：① → ② → ③ → ④ ?
(假设 a, b, c, d 为值 r.v.)

$$P(d) = \sum_{abc} P(a, b, c, d)$$

$a, b, c, d \in \{0, 1\}$

$$= \sum_{a,b,c} P(a) P(b|a) P(c|b) P(d|c)$$

$$= P(a=0) P(b=0|a=0) P(c=0|b=0) P(d|c=0)$$

$$+ P(a=1) P(b=0|a=1) P(c=0|b=0) P(d|c=0)$$

:

$$+ P(a=1) P(b=1|a=1) P(c=1|b=1) P(d|c=1)$$

$$= 8 \times \text{因子积}$$

可以发现，此时仅有 a, b, c, d 4 个二值变量，若有 N 个变量，每个变量取值为 k，则共 k^N 项

P2. Variable Elimination.

例如有马氏程： $\textcircled{a} \rightarrow \textcircled{b} \rightarrow \textcircled{c} \rightarrow \textcircled{d}$? (假设 a, b, c, d 为二值 r.v.)
 $a, b, c, d \in \{0, 1\}$

$$\begin{aligned}
 P(d) &= \sum_{abc} P(a, b, c, d) \\
 &= \sum_{a,b,c} P(a) P(b|a) P(c|b) P(d|c) \\
 &= P(a=0) P(b=0|a=0) P(c=0|b=0) P(d|c=0) \\
 &\quad + P(a=1) P(b=0|a=1) P(c=0|b=0) P(d|c=0) \\
 &\quad : \\
 &\quad + P(a=1) P(b=1|a=1) P(c=1|b=1) P(d|c=1) \\
 &= 8 \times \text{因子积.}
 \end{aligned}$$

可以发现，此时仅有 a, b, c, d 4 个二值变量，若有 N 个变量，每个变量取值为 k ，则共 k^N 项。

观察式子，并不是所有的因子都与某个变量相关，因此，可以写为：

$$\begin{aligned}
 &= \sum_{b,c} P(c|b) \cdot P(d|c) \cdot \underbrace{\sum_a P(a) P(b|a)}_{m_a(b)} \\
 &= \sum_c P(d|c) \underbrace{\sum_b P(c|b) m_a(b)}_{m_b(c)} \\
 &= \sum_c P(d|c) m_b(c) \\
 &= m_c(d)
 \end{aligned}$$


这种思想可以看做是乘法对加法的分配律

对于无向图：

$$P(X) = \frac{1}{Z} \prod_i^k \phi_{c_i}(x_{c_i}) \cdot \frac{1}{Z} \phi_{a_i}(x_{a_i}) \text{ 可以作为因子.}$$

缺点：
① 重复计算，计算步骤无法存储，每次计算一个边缘概率就要重新计算一遍整个图。
② ordering，变量消除次序，是一个 NP-hard 问题

P3. VE To Belief Propagation



计算 $P(e)$:

$$P(e) = \sum_{a,b,c,d} P(a,b,c,d,e) = \sum_a P(e|d) \sum_c P(d|c) \sum_b P(c|b) \underbrace{\sum_a P(b|a) P(a)}_{m_{a \rightarrow b}(a)} \\ \underbrace{\sum_c P(b|c) P(c)}_{m_{b \rightarrow c}(c)} \underbrace{\sum_d P(d|c) P(c)}_{m_{c \rightarrow d}(d)} \underbrace{\sum_e P(e|d) P(d)}_{m_{d \rightarrow e}(e)}$$


计算 $P(c)$:

$$P(c) = \sum_{a,b,d,e} P(a,b,c,d,e) = \sum_{a,b,d} P(a) P(b|a) P(c|b) P(d|c) P(e|d) \\ = (\sum_b P(c|b) \sum_a P(b|a) P(a)) \cdot (\sum_d P(d|c) \sum_e P(e|d))$$

可以发现在计算 $P(c)$ 时前半部分的计算与 $P(e)$ 有重复，若计算其它边缘概率，也会有重复。而 BP 就是用来解决这个问题。

Belief Propagation 3/4 出

上面我们一直计算的是有向图的 Markov Chain，现在将问题从链结构引申到树结构，从有向图引申到无向图，例如有如下无向图：



其联合概率因子分解可以写为：

$$P(a, b, c, d) = \prod \psi_a(a) \psi_b(b) \psi_c(c) \psi_d(d) \psi_{ab}(a, b) \psi_{bc}(b, c) \psi_{bd}(b, d)$$

我们只要求出 6 个边，就能求出图中任意变量的边缘概率。

$$P(a) = \sum_{b,c,d} P(a, b, c, d) = \psi_a \sum_b \psi_{ab} \left(\sum_c \psi_{bc} \cdot \psi_{bd} \right) \cdot \left(\sum_d \psi_{ad} \cdot \psi_{bd} \right) \\ \underbrace{\sum_b \psi_{ab} \cdot \psi_{bc}}_{m_{c \rightarrow b}(b)} \underbrace{\sum_d \psi_{ad} \cdot \psi_{bd}}_{m_{d \rightarrow b}(b)} \\ \underbrace{\sum_b \psi_{ab}}_{m_{b \rightarrow a}(a)}$$

$$\left\{ \begin{array}{l} m_{b \rightarrow a}(x_a) = \sum_{x_b} \psi_{ab} \cdot \psi_b \cdot m_{c \rightarrow b}(x_b) \cdot m_{d \rightarrow b}(x_b) \\ P(x_a) = \psi_a \cdot m_{b \rightarrow a}(x_a) \end{array} \right.$$

$$\left\{ \begin{array}{l} m_{j \rightarrow i}(x_i) = \sum_{x_j} \psi_{ij} \cdot \psi_j \cdot \prod_{k \in N(j) \setminus i} m_{k \rightarrow j}(x_j) \\ P(x_i) = \psi_i \cdot \prod_{k \in N(i)} m_{k \rightarrow i}(x_i) \end{array} \right.$$

★不要直接求边缘概率($P(a), P(b), \dots$), 只需求所有的 $m_{i \rightarrow j}$ 即可.
这就是P要做的.

$$m_{b \rightarrow a} = \sum_b \underbrace{\psi_{ab}}_{self} \cdot \underbrace{\psi_b}_{children} \cdot \underbrace{m_{c \rightarrow b} \cdot m_{d \rightarrow b}}_{belief(b)}$$

$$\left\{ \begin{array}{l} belief(b) = \psi_b \cdot children \\ m_{b \rightarrow a} = \sum_b \psi_{ab} \cdot belief(b) \end{array} \right.$$

belief(b) 是 b 所能提供的信息量.

信念传播算法首先求所有的信息传递(收集或分发)的过程得到所有的 $m_{i \rightarrow j}$ (图的遍历)
然后套用公式计算边缘概率, PP BP = VE + Caching

BP遍历图的一种方法 (Sequential Implementation) 如下:

① 选择一个节点作为根节点, 假定为 a.

② 收集消息(即图中蓝线):

for x_i in Neighbor(Root):

collectMsg(x_i)

③ 分发消息(即图中红线):

for x_i in Neighbor(Root):

distributeMsg(x_i)

遍历完成后可得所有 $m_{i \rightarrow j}$, 则 $P(x_k)$ 可求.